

ĐẠI HỌC QUỐC GIA THÀNH PHỐ HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN
KHOA CÔNG NGHỆ THÔNG TIN



Statistical Learning

Final Semester Lab: Object Detection Application

Sinh viên thực hiện:

Nguyễn Văn Linh (23122003)
Nguyễn Thị Mỹ Kim (23122040)
Đoàn Quang Thắng (23122051)

Giảng viên hướng dẫn:

T.S Ngô Minh Nhật
Th.S Lê Long Quốc

Contents

1	Giới thiệu tổng quan	2
2	Tập dữ liệu Fisheye8K	2
2.1	Tổng quan	2
2.2	Quy trình phân chia tập dữ liệu	2
2.3	Lý do chọn tập Fisheye8K	2
3	Metrics đánh giá mô hình	2
4	Mô hình YOLOv10-S	3
4.1	Tổng quan	3
4.2	Kết quả của quá trình huấn luyện	4
4.3	Nhận xét kết quả huấn luyện	4
4.4	Kết luận	5
5	Mô hình RT-DETR	5
5.1	Tổng quan	5
5.2	Kết quả quá trình huấn luyện	5
5.3	Nhận xét kết quả huấn luyện	6
5.4	Kết luận	7
6	Mô hình Faster-CNN	7
6.1	Tổng quan kiến trúc mô hình	7
6.1.1	R-CNN (Regions with CNN features)	7
6.1.2	Faster R-CNN	8
6.1.3	Các Key Features	8
6.1.4	Kiến trúc mô hình	8
6.2	Kết quả quá trình huấn luyện	9
6.3	Nhận xét kết quả huấn luyện	10
6.4	Kết luận	10
7	So sánh Hiệu năng giữa các mô hình	11

1 Giới thiệu tổng quan

Trong đề án này, nhóm thực hiện tinh chỉnh các mô hình YOLOv10-S, RT-DETR và Faster R-CNN trên tập dữ liệu Fisheye8K cho bài toán **Object Detection**, sau đó đưa ra các đánh giá giữa các mô hình trên và xây dựng một trang web đơn giản ứng dụng mô hình đã huấn luyện cho bài toán nhận diện phương tiện (tốt nhất là từ hình ảnh camera fisheye trên đường phố).

2 Tập dữ liệu Fisheye8K

2.1 Tổng quan

Trong đề án này, nhóm đã lựa chọn tập dữ liệu **Fisheye8K** cho quá trình tinh chỉnh mô hình. **Fisheye8K** là tập dữ liệu quy mô lớn với tổng cộng 8.553 hình ảnh chất lượng cao. Dữ liệu được trích xuất trực tiếp từ hệ thống 18 camera giám sát giao thông thực tế tại thành phố Tân Trú, Đài Loan, ghi nhận hơn 157.000 khung hình bao đóng (bounding boxes) được gắn nhãn thủ công kỹ lưỡng. Tập dữ liệu này phân chia cấu trúc thành 5 lớp đối tượng đặc trưng bao gồm: *Pedestrian*, *Bike*, *Car*, *Bus* và *Truck*. Do đặc thù thấu kính mắt cá, các hình ảnh sở hữu góc nhìn rộng nhưng bị biến dạng quang học mạnh ở vùng rìa, mang lại thách thức lớn cho bài toán nhận diện luồng giao thông đô thị.

2.2 Quy trình phân chia tập dữ liệu

Để chuẩn bị cho quá trình tinh chỉnh và đánh giá khách quan các mô hình, tập dữ liệu gốc được phân chia thành hai tập con độc lập: tập huấn luyện (*Training set*) và tập kiểm thử (*Validation set*) với tỉ lệ **80% train** và **20% validation**.

Quy trình cụ thể được thực hiện qua các bước: (1) Lọc toàn bộ danh sách tệp ảnh hợp lệ và thiết lập hạt giống ngẫu nhiên cố định ($\text{seed} = 42$) để đảm bảo tính tái lập; (2) Xáo trộn ngẫu nhiên danh sách và tiến hành phân cắt ngẫu nhiên dữ liệu theo tỷ lệ $\alpha = 0.8$ nhằm tách biệt hai tập con; (3) Khởi tạo cấu trúc thư mục mới, thực hiện sao chép đồng thời tệp hình ảnh và tệp nhãn `.txt` tương ứng, kết hợp cơ chế kiểm tra lỗi đọc lặp để phát hiện các trường hợp khuyết nhãn.

Kết quả của quy trình này tạo ra hai tập dữ liệu chuẩn hóa, sẵn sàng cung cấp cho luồng huấn luyện thông qua cấu hình trong tệp `data.yaml` của thư viện `ultralytics`.

Lưu ý về tập kiểm thử độc lập (Test set): Tập dữ liệu *Test* được giữ nguyên vẹn từ phân phối gốc của ban tổ chức Fisheye8K và hoàn toàn độc lập với quy trình phân chia nội bộ nêu trên. Tập dữ liệu này chỉ được sử dụng một lần duy nhất trong các tệp cấu hình đánh giá để đảm bảo tính khách quan tối đa cho các chỉ số đo lường hiệu năng mô hình.

2.3 Lý do chọn tập Fisheye8K

Đây là một bài toán khó nhưng cũng khá nhỏ về kích thước, phù hợp với tiêu chí huấn luyện tinh chỉnh trên các mô hình nên nhóm đã quyết định chọn tập Fisheye8K làm dataset cho đề án này.

3 Metrics đánh giá mô hình

Để đánh giá toàn diện hiệu năng của các mô hình phát hiện đối tượng, nhóm sử dụng các chỉ số tiêu chuẩn trong bài toán thị giác máy tính bao gồm: Độ chính xác (*Precision*), Độ bao phủ (*Recall*), Điểm F1 (*F1-Score*) và Độ chính xác trung bình đơn điệu (*mean Average Precision - mAP*). Tuy nhiên, việc định nghĩa các thông số True Positive (TP), False Positive (FP) và False Negative (FN) có đôi chút khác biệt để phù hợp với bài toán vừa phân loại, vừa đánh khung - bounding box. Cụ thể, các chỉ số này được tính toán dựa

trên bốn trạng thái phân loại của khung hình bao đóng so với nhãn gốc thông qua giá trị ngưỡng giao cắt góc (*Intersection over Union - IoU*):

- **True Positive (TP)**: Mô hình dự đoán chính xác sự tồn tại và vị trí của vật thể (vị trí khung hình dự đoán có độ khớp **IoU** vượt ngưỡng cho trước).
- **False Positive (FP)**: Mô hình hoặc nhận nhầm background thành vật thể, hoặc phân loại sai nhãn, hoặc phân loại đúng nhưng bounding box có **IoU** dưới ngưỡng, hoặc bắt cùng 1 vật thể nhiều lần - chỉ có bounding box tốt nhất là TP, còn lại là FP.
- **False Negative (FN)**: Mô hình bỏ sót vật thể thực tế có trên ảnh.

Các chỉ số Precision, Recall, F1 vẫn được tính theo công thức gốc.

Độ chính xác (Precision)

$$\text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}} \quad (1)$$

Độ bao phủ (Recall)

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}} \quad (2)$$

Điểm F1 (F1-Score)

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3)$$

Độ chính xác trung bình đơn điệu (mAP)

Nhóm còn sử dụng thêm chỉ số mAP, một chỉ số quan trọng cho việc đánh giá các mô hình cho bài toán phân loại + đánh khung, được xác định bằng độ chính xác trung bình giữa các lớp.

$$\text{mAP} = \frac{1}{C} \sum_{i=1}^C \text{AP}_i \quad (4)$$

Trong thực nghiệm, hệ thống trích xuất hai giá trị mAP cốt lõi theo tiêu chuẩn của thư viện **ultralytics**:

- **mAP@0.5 (mAP50)**: Giá trị mAP được tính toán tại một ngưỡng cố định $\text{IoU} = 0.5$. Chỉ số này đánh giá khả năng định danh phân lớp tổng thể của mô hình.
- **mAP@0.5:0.95 (mAP50-95)**: Giá trị mAP trung bình được tính toán trên chuỗi các ngưỡng IoU biến thiên liên tục từ 0.5 đến 0.95 với bước nhảy 0.05. Đây là chỉ số khắt khe, đòi hỏi mô hình không chỉ đoán đúng nhãn mà còn phải tối ưu độ chính xác hình học của các đường biên bao đóng.

4 Mô hình YOLOv10-S

4.1 Tổng quan

Mô hình **YOLOv10** được xây dựng trên kiến trúc của **YOLOv8** với nhiều cải tiến vượt trội, được giới thiệu bởi nhóm nghiên cứu tại Đại học Thanh Hoa vào năm 2024 nhằm giải quyết triệt để nút thắt cổ chai về độ trễ gây ra bởi thuật toán hậu xử lý NMS (Non-Maximum Suppression) truyền thống. Mục đích cốt lõi của mô hình là thiết lập một giải pháp phát hiện đối tượng **đầu-cuối** (End-to-End) thông qua cơ chế **gán nhãn kép đồng nhất** (Consistent Dual Assignments), loại bỏ hoàn toàn bước hậu xử lý phức tạp - **NMS** để tối ưu tốc độ suy diễn trực tiếp trên các thiết bị biên. Để đáp ứng các nhu cầu khắt khe về mặt tài nguyên và hiệu năng thực tế, YOLOv10 mang đến chuỗi cải tiến đột phá bao gồm cấu trúc khối xếp chồng hiệu quả như các khối **SCDown** (Spatial Channel Downsampling), khối **C2fCIB**, **hệ thống chú ý toàn cục kích thước lớn** (Large-kernel convolutions) và **hệ thống chú ý phân đoạn** (Partial Self-Attention) nhằm giảm thiểu tối đa chi phí tính toán FLOPs không cần thiết.

Theo công bố trong bài báo khoa học, họ mô hình YOLOv10 được phát hành với cấu trúc phân cấp đa dạng đáp ứng nhiều quy mô phần cứng khác nhau bao gồm 6 phiên bản: YOLOv10-N (Nano), YOLOv10-S (Small), YOLOv10-M (Medium), YOLOv10-B (Balanced), YOLOv10-L (Large) và YOLOv10-X (Extra Large). Trong đó, biến thể **YOLOv10-S** mà nhóm sử dụng đại diện cho sự cân bằng hoàn hảo giữa hiệu năng và dung lượng mạng khi sở hữu cấu hình tinh gọn với xấp xỉ **7.2 triệu tham số** (7,219,935 parameters), giúp mô hình đạt tốc độ vượt trội và trở thành lựa chọn tối ưu cho các bài toán nhận diện luồng giao thông đô thị phức tạp.

4.2 Kết quả của quá trình huấn luyện




Figure 1: Các đường cong phân tích hiệu năng của mô hình YOLOv10-S trên tập dữ liệu Fisheye8K tại các ngưỡng tin cậy khác nhau.




Figure 2: Ma trận nhầm lẫn đánh giá khả năng phân loại các lớp đối tượng giao thông của mô hình YOLOv10-S trên tập dữ liệu Fisheye8K.

4.3 Nhận xét kết quả huấn luyện

Dựa vào các kết quả thu được ở trên, ta có:

- Từ ma trận nhầm lẫn - confusion matrix: Mô hình nhận diện tốt các lớp như "car" và "bike" với số lượng dự đoán đúng cao, tuy nhiên vẫn tồn tại sự nhầm lẫn đáng kể giữa các đối tượng và "background", cũng như giữa một số lớp đối tượng với nhau.
- Dựa vào đường cong F1 so với Confidence: đạt đỉnh khoảng 0.50 tại ngưỡng Confidence 0.3, trong đó lớp "car" đạt hiệu suất F1 tốt nhất so với các lớp còn lại.
- Dựa vào đường cong Precision và Recall: Precision tăng dần theo Confidence và đạt mức 1.00 tại Confidence 1.000; Recall giảm dần khi Confidence tăng. Điều này phản ánh mô hình dự đoán tin cậy

khi ngưỡng Confidence càng cao, tuy nhiên đánh đổi là mô hình không phát hiện được đa dạng vật thể khác.

- Dựa vào đường cong PR: Chỉ số mAP@0.5 tổng hợp đạt 0.458, với lớp "car" (0.621) và "bus" (0.570) cho thấy mô hình hoạt động ổn định nhất trên các đối tượng kích thước lớn hoặc đặc trưng rõ ràng.

4.4 Kết luận

Điểm mạnh: Mô hình **YOLOv10-S** sở hữu điểm mạnh cốt lõi là cơ chế gán nhãn kép đồng nhất giúp loại bỏ hoàn toàn hậu xử lý NMS, triệt tiêu hiện tượng thất cổ chai tính toán và tối ưu tốc độ suy diễn thời gian thực vượt trội (nhanh hơn gấp 1,8 lần mạng Transformer RT-DETR-R18 ở cùng mức chính xác). Song song đó, kiến trúc tích hợp các khối cải tiến **C2fCIB** và **SCDown** mang lại cấu hình cực kỳ tinh gọn với xấp xỉ 8,07 triệu tham số, giúp tiết kiệm tài nguyên VRAM và tăng khả năng trích xuất đặc trưng hình học tại vùng biên ảnh biến dạng quang học của camera mất cân.

Điểm yếu: Tuy nhiên, điểm yếu của mô hình nằm ở việc gia tăng chi phí tính toán (Overhead) trong quá trình huấn luyện do duy trì hai đầu phân loại, đồng thời ma trận nhầm lẫn thực nghiệm cho thấy tỷ lệ nhận nhầm các vật thể nhỏ hoặc quá xa (như *Pedestrian* và *Bike*) sang lớp nền (*background*) vẫn còn tồn tại.

Kết luận YOLOv10-S là giải pháp lý tưởng trong thực tế để triển khai trực tiếp trên các thiết bị biên giới hạn tài nguyên như NVIDIA Jetson hoặc camera thông minh phục vụ hệ thống giám sát lưu lượng giao thông đô thị góc rộng, đếm phương tiện và hỗ trợ robot tự hành điều hướng thời gian thực nhờ vào kiến trúc tinh gọn nhưng không làm suy giảm hiệu năng quá lớn (tradeoff tốt).

5 Mô hình RT-DETR

5.1 Tổng quan

RT-DETR (Real-Time DEtection Transformer) là mô hình phát hiện đối tượng thời gian thực đầu tiên dựa trên kiến trúc Transformer vượt qua các mô hình dạng YOLO tiên tiến về cả độ chính xác lẫn tốc độ xử lý. Được phát triển nhằm khắc phục nhược điểm về độ trễ lớn của các mạng DETR truyền thống, RT-DETR giới thiệu một kiến trúc đột phá gồm hai thành phần lõi: bộ mã hóa lai hiệu quả **Efficient Hybrid Encoder** giúp xử lý các đặc trưng đa quy mô bằng cách tách biệt tương tác nội quy mô (intra-scale) và tương tác chéo quy mô (cross-scale); kết hợp cùng cơ chế **IoU-aware Query Selection** để khởi tạo các truy vấn đối tượng chất lượng cao trực tiếp dựa trên các hộp dự đoán có độ chính xác hình học tốt nhất.

Trong đề án này, nhóm lựa chọn cấu hình **RT-DETR-L** (phiên bản cấu trúc lớn - Large). Sự kết hợp này cho phép mô hình giải quyết triệt để bài toán phát hiện đối tượng góc rộng mà không cần sử dụng đến thuật toán hậu xử lý NMS (Non-Maximum Suppression). Bằng cách thay đổi linh hoạt số lượng layer trong bộ giải mã (Decoder), RT-DETR-L hỗ trợ điều chỉnh tốc độ suy diễn một cách chủ động mà không cần phải thực hiện huấn luyện lại từ đầu, mang lại khả năng tùy biến và tối ưu vượt trội trên các hệ thống giám sát giao thông thông minh.

5.2 Kết quả quá trình huấn luyện

Để phân tích định lượng hiệu năng thực nghiệm của mạng Transformer RT-DETR-L trên tập dữ liệu ảnh giao thông biến dạng mất cân Fisheye8K, hệ thống trích xuất chuỗi đường cong hiệu năng đặc trưng theo các ngưỡng tin cậy phân loại cùng hệ thống ma trận nhầm lẫn chi tiết dưới đây:




Figure 3: Các đường cong phân tích hiệu năng của mô hình RT-DETR trên tập dữ liệu Fisheye8K tại các ngưỡng tin cậy khác nhau.




Figure 4: Ma trận nhầm lẫn đánh giá khả năng phân loại các lớp đối tượng giao thông của mô hình RT-DETR trên tập dữ liệu Fisheye8K.

5.3 Nhận xét kết quả huấn luyện

Dựa vào các kết quả đồ thị thực nghiệm và ma trận nhầm lẫn thu được, nhóm đưa ra các nhận xét cụ thể như sau:

- **Từ ma trận nhầm lẫn (Confusion Matrix):** RT-DETR-L chứng minh sức mạnh áp đảo của kiến trúc Attention Vision toàn cục khi đạt tỷ lệ nhận diện chính xác cực kỳ cao và đồng đều trên tất cả các phân lớp đối tượng. Tại ma trận chuẩn hóa, mô hình định danh đúng 0.98 lớp *car*, 0.97 lớp *bike*, 0.95 lớp *bus*, 0.92 lớp *pedestrian* và 0.90 lớp *truck*. Đáng chú ý, tỷ lệ các vật thể bị bỏ sót hoặc nhận nhầm sang lớp nền (*background*) được kiểm soát ở mức cực thấp (chỉ dao động từ 0.01 đến 0.06), giải quyết triệt để điểm yếu cố hữu về hiện tượng sót vật thể nhỏ của Faster R-CNN hay YOLOv10-S. Tuy nhiên, vẫn tồn tại một tỷ lệ nhầm lẫn nhỏ từ thực thể nền sang lớp xe máy (*bike* bị dự đoán nhầm từ *background* là 0.59 ở góc nhìn thô), do đặc thù phân phối ảnh giao thông mất cá chứa nhiều nhiễu ràng cưa tại các vùng biên.
- **Dựa trên đường cong F1-Confidence Curve:** Đường cong F1 của toàn bộ các lớp (all classes) đạt đỉnh rất cao với giá trị 0.92 tại ngưỡng tin cậy lý tưởng Confidence = 0.623. Đồ thị F1 dạng hình vòm mở rộng trên dải Confidence từ 0.2 đến 0.7 chứng tỏ tính ổn định vượt trội của mô hình; trong đó lớp *car* duy trì hiệu suất tiệm cận mức 0.95, và ngay cả phân lớp khó như *pedestrian* cũng đạt đỉnh F1 trên mạng lưới Transformer này ở mức gần 0.88.
- **Dựa trên đường cong Precision và Recall theo Confidence:** Precision toàn cục duy trì mức xuất phát quanh 0.15 tại Confidence = 0.00 và nhanh chóng dốc lên, đạt trạng thái hoàn hảo 1.00 tại ngưỡng 1.000. Điểm đột phá nằm ở đường cong Recall: tại ngưỡng Confidence = 0.000, độ bao phủ

đạt mức gần như tuyệt đối là 0.98. Đồ thị Recall giữ được độ phẳng kéo dài và chỉ thực sự sụt giảm mạnh khi ngưỡng Confidence vượt quá mức 0.7, thể hiện khả năng giữ lại tối đa lượng True Positives mà không bị đánh đổi quá sớm.

- **Dựa trên đường cong Precision-Recall (PR Curve):** Chỉ số độ chính xác trung bình đơn điều mAP@0.5 toàn cục đạt điểm số kỷ lục là **0.954**. Sự phân hóa hiệu năng giữa các lớp được thu hẹp tối đa: lớp *car* dẫn đầu với 0.984, tiếp theo là *bus* (0.966), *bike* (0.965), *truck* (0.948), và lớp có kích thước hình học nhỏ nhất là *pedestrian* cũng đạt tới chỉ số ấn tượng là 0.909.

5.4 Kết luận

Điểm mạnh: Mô hình **RT-DETR-L** thể hiện hiệu năng nhận diện hoàn hảo và toàn diện nhất trong số các mô hình được thử nghiệm. Sức mạnh này đến từ cơ chế tự chú ý (Self-Attention) cho phép mô hình thiết lập mối quan hệ ngữ cảnh xa giữa các pixel, từ đó loại bỏ hoàn toàn các sai số định vị do thấu kính camera mất cá làm cong biến dạng vật thể. Khả năng đẩy mAP@0.5 lên mức 0.954 cùng tỷ lệ bỏ sót vật thể tiệm cận bằng không chứng minh cấu trúc Hybrid Encoder và các truy vấn IoU-aware hoạt động cực kỳ hiệu quả trên bài toán giao thông đô thị phức tạp.

Điểm yếu: Mặc dù sở hữu độ chính xác lý tưởng, điểm yếu lớn nhất của RT-DETR-L nằm ở độ nặng của kiến trúc hệ thống. Là một mô hình thuộc phân khúc cấu trúc lớn (Large), số lượng tham số đồ sộ của mạng (xấp xỉ **32 triệu tham số** cùng lượng tính toán FLOPs rất lớn, gấp gần 4.5 lần so với YOLOv10-S) dẫn đến chi phí bộ nhớ VRAM khi huấn luyện cực kỳ cao. Gánh nặng phần cứng này khiến mô hình gặp bất lợi lớn về mặt phân bổ tài nguyên, làm giảm tốc độ suy diễn thực tế và rất khó khăn khi triển khai trực tiếp trên các vi điều khiển hoặc thiết bị IoT biên giới hạn năng lượng.

Kết luận: Nhìn chung, RT-DETR-L là mô hình tối ưu tuyệt đối về mặt chất lượng nhận diện, thiết lập một cột mốc hiệu năng cao cho bài toán phân tích luồng giao thông góc rộng Fisheye8K. Mô hình là sự lựa chọn không thể thay thế cho các ứng dụng trung tâm điều hành giao thông thông minh (Smart City Hub), nơi đòi hỏi độ chính xác kiểm đếm và nhận dạng hành vi phương tiện ở mức gần như tuyệt đối và được vận hành trên các hệ thống máy chủ tính toán mạnh mẽ, chấp nhận đánh đổi (trade-off) về mặt kích thước mô hình để lấy hiệu năng tối đa.

6 Mô hình Faster-CNN

Object Detection gồm 2 task chính là Classification (phân loại đối tượng) và Bounding Box Regression (xác định chính xác vị trí của Bounding Box). Sự đột phá của **Faster R-CNN** nằm ở việc thiết kế ra mạng **RPN** để hợp nhất hoàn toàn quá trình "tìm vùng" và "nhận dạng" vào chung một hệ thống mạng nơ-ron học sâu (End-to-End). Bằng cách tái sử dụng (share) Feature Map cho cả 2 tác vụ, hệ thống đạt tốc độ xử lý gần như thời gian thực (real-time) và độ chính xác (mAP) vượt trội so với các thể hệ R-CNN trước đó.

6.1 Tổng quan kiến trúc mô hình

6.1.1 R-CNN (Regions with CNN features)

R-CNN là multi-stage pipeline: **Bước 1 - Trích xuất vùng (Region Proposals):** Sử dụng thuật toán truyền thống *Selective Search* để quét qua ảnh và tìm ra khoảng 2000 vùng có khả năng chứa đối tượng. **Bước 2 - Warp/Crop:** Cắt và thay đổi kích thước (resize) 2000 vùng này về cùng một kích thước cố định. **Bước 3 - Trích xuất đặc trưng (Feature Extraction):** Đưa từng vùng một qua mạng CNN (như ResNet50) để trích xuất vector đặc trưng. (Đây là bước gây chậm nhất vì phải tính toán CNN 2000 lần cho một bức ảnh). **Bước 4 - Phân loại & Hồi quy:** Đưa đặc trưng vào máy học SVM để phân loại và một mô hình hồi quy để tinh chỉnh lại tọa độ bounding box.

Nhược điểm: Tốc độ rất chậm (khoảng 47 giây/ảnh), huấn luyện rời rạc từng module, tốn bộ nhớ lưu trữ đặc trưng.

6.1.2 Faster R-CNN

Faster R-CNN giải quyết hoàn toàn nút thắt cổ chai của R-CNN và Fast R-CNN trước đó: *Thuật toán tìm vùng (Region Proposal) quá chậm*. Cơ chế cốt lõi của Faster R-CNN là: **Dùng chung tính toán (Shared Computation):** Đưa toàn bộ bức ảnh qua mạng CNN **chỉ một lần** để lấy *Feature Map* chung. **Loại bỏ Selective Search:** Đưa ra mạng **Region Proposal Network (RPN)** để mạng nơ-ron tự học cách dự đoán vùng chứa đối tượng thay vì dùng thuật toán thủ công. **Gộp mạng:** Kết hợp RPN và Fast R-CNN vào chung một mạng (End-to-End unified network). Faster R-CNN = RPN + Fast R-CNN.

6.1.3 Các Key Features

- **Region Proposal Network (RPN):** Là một mạng Fully Convolutional Network (FCN) nhận đầu vào là feature map của ảnh và đầu ra là một tập hợp các bounding box kèm theo objectness score.
- **Anchor Boxes:** Để giải quyết vấn đề đối tượng có nhiều kích thước (scale) và tỷ lệ khung hình (aspect ratio) khác nhau, RPN sử dụng các Anchor Boxes cố định. Tại mỗi vị trí cửa sổ trượt (sliding window) trên Feature Map, RPN dự đoán cùng lúc k Anchor Boxes (thường $k = 9$, với 3 scale và 3 tỷ lệ). Điều này giúp mô hình *Translation-Invariant* và không cần phải tạo ra nhiều ảnh với các kích thước khác nhau (image pyramid).
- **Hàm mất mát đa tác vụ (Multi-task Loss):** RPN được tối ưu hóa thông qua một hàm loss kết hợp giữa phân loại (chứa đối tượng hay nền) và hồi quy (độ lệch tọa độ hộp).

$$L(\{p_i\}, \{t_i\}) = \frac{1}{N_{cls}} \sum_i L_{cls}(p_i, p_i^*) + \lambda \frac{1}{N_{reg}} \sum_i p_i^* L_{reg}(t_i, t_i^*) \quad (5)$$

Trong đó: p_i là xác suất chứa đối tượng, t_i là vector 4 tọa độ của bounding box.

6.1.4 Kiến trúc mô hình

1. Backbone Network (Mạng trích xuất đặc trưng cơ sở)

Thường sử dụng các mạng CNN như VGG-16 hoặc ResNet. **Chức năng:** Nhận ảnh đầu vào (ví dụ: $H \times W \times 3$) và đi qua các lớp Convolution, ReLU, Max Pooling. **Đầu ra:** Một *Feature Map* tóm tắt đặc trưng của toàn bộ bức ảnh (ví dụ kích thước được giảm đi 16 lần: $\frac{H}{16} \times \frac{W}{16} \times C$).

2. Region Proposal Network (RPN) RPN trực tiếp xử lý Feature Map từ Backbone:

Dùng một cửa sổ trượt (*sliding window* - thường là lớp Conv 3×3) quét qua Feature Map. Tại mỗi vị trí, nó sinh ra một vector đặc trưng trung gian có số chiều thấp hơn (ví dụ 256). Từ vector này, nó chia làm 2 nhánh song song (*sibling layers*) bằng các lớp Conv 1×1 :

- **Lớp Phân loại (cls layer):** Đầu ra có kích thước $2k$. Tại mỗi vị trí với k Anchor boxes, nó dự đoán 2 giá trị xác suất (Là Đối tượng hay Không là Đối tượng / Background).
- **Lớp Hồi quy (reg layer):** Đầu ra có kích thước $4k$. Tại mỗi vị trí với k Anchor, nó dự đoán 4 giá trị (x, y, w, h) đại diện cho độ lệch (offset) cần thiết để tinh chỉnh Anchor box thành Bounding box thực tế.
- Các vùng ứng viên tốt nhất (Proposals) sẽ được chọn lọc thông qua Non-Maximum Suppression (NMS) để loại bỏ các hộp chồng chéo.

3. RoI Pooling (Region of Interest Pooling) Mạng RPN trả về các vùng Proposal có kích thước và tỷ lệ khác nhau. Tuy nhiên, các lớp Fully Connected ở phần sau lại yêu cầu kích thước đầu vào cố định. **Chức năng:** Lấy tọa độ của các Region Proposals (từ RPN) chiếu lên *Feature Map chung* (từ Backbone), cắt vùng đặc trưng đó ra và áp dụng *Max Pooling* để ép chúng về một kích thước cố định (ví dụ 7×7).

4. Phân loại và Hồi quy cuối cùng (Fast R-CNN Head) Feature Map cố định từ RoI Pooling được duỗi phẳng (flatten) và đưa qua các lớp Fully Connected (FC layers). Tương tự như RPN, nhánh này cũng chia làm hai đầu ra nhưng với mục đích cụ thể hơn:

- **Softmax Classifier:** Dự đoán nhãn lớp cụ thể của đối tượng (Dog, Cat, Car,...) cộng thêm 1 lớp Background.
- **Bounding Box Regressor:** Tiếp tục tinh chỉnh tọa độ bounding box một lần nữa cho riêng từng lớp cụ thể để đạt độ chính xác tối đa.

6.2 Kết quả quá trình huấn luyện

Để đánh giá một cách toàn diện và trực quan hiệu năng của mô hình Faster R-CNN trên tập dữ liệu giao thông mất cá Fisheye8K, hệ thống đã trích xuất chuỗi đường cong biến thiên đặc trưng (Precision, Recall, F1-Score) theo các ngưỡng tin cậy (Confidence threshold), cùng với ma trận nhầm lẫn tổng thể và ma trận nhầm lẫn chuẩn hóa.




Figure 5: Các đường cong phân tích hiệu năng của mô hình Faster R-CNN trên tập dữ liệu Fisheye8K tại các ngưỡng tin cậy khác nhau.




Figure 6: Ma trận nhầm lẫn đánh giá khả năng phân loại các lớp đối tượng giao thông của mô hình Faster R-CNN trên tập dữ liệu Fisheye8K.

6.3 Nhận xét kết quả huấn luyện

Dựa trên tập hợp các biểu đồ trực quan hóa kết quả thực nghiệm thu được từ quá trình đánh giá mô hình Faster R-CNN, nhóm đưa ra các nhận xét và phân tích định lượng cụ thể như sau:

- Từ ma trận nhầm lẫn (Confusion Matrix):** Mô hình thể hiện khả năng nhận diện phân loại tương đối ổn định trên các lớp đối tượng có mật độ xuất hiện lớn là *car* (đạt tỷ lệ chính xác 0.55 trên tập chuẩn hóa) và *bike* (đạt 0.52). Khả năng nhận diện lớp *bus* đạt mức trung bình với tỷ lệ 0.52, tuy nhiên mô hình gặp thách thức rất lớn ở các lớp *truck* (0.33) và đặc biệt là *pedestrian* (0.20). Nguyên nhân cốt lõi dẫn đến sự suy giảm này là hiện tượng bỏ sót vật thể sang lớp nền, với tỷ lệ nhầm *pedestrian* và *truck* thành *background* lần lượt lên tới 0.64 và 0.55. Điều này cho thấy kiến trúc vùng đề xuất RPN truyền thống gặp khó khăn khi trích xuất các vật thể bị biến dạng mạnh hoặc có kích thước quá nhỏ trong không gian thấu kính mắt cá.
- Dựa trên đường cong F1-Confidence Curve:** Chỉ số F1-Score toàn cục (all classes) đạt giá trị đỉnh tương đối khiêm tốn là 0.32 tại ngưỡng tin cậy khá cao $\text{Confidence} = 0.727$. Xét theo từng thực thể lớp độc lập, *car* (đường màu xanh lá) giữ vị thế dẫn đầu khi duy trì dải F1 ổn định tiệm cận mức 0.58, theo sau lần lượt là *bike* (0.46), *truck* (0.22), *bus* và *pedestrian* đều nằm ở phân khúc dưới 0.20.
- Dựa trên đường cong Precision và Recall theo Confidence:** Đường cong Precision tịnh tiến tỷ lệ thuận với việc nâng cao ngưỡng tin cậy, đạt trạng thái phân loại lý tưởng toàn cục 1.00 tại ngưỡng $\text{Confidence} = 1.000$. Ngược lại, đường cong Recall có xu hướng dốc xuống liên tục khi Confidence tăng dần; tại điểm xuất phát ($\text{Confidence} = 0.000$), độ bao phủ toàn cục chỉ chạm ngưỡng tối đa 0.51. Sự đánh đổi (trade-off) sâu sắc này minh chứng rằng Faster R-CNN kiểm soát phân loại sai (FP) rất tốt ở ngưỡng tin cậy cao, song lại chịu tổn thất nặng nề về số lượng vật thể bị bỏ sót (FN).
- Dựa trên đường cong Precision-Recall (PR Curve):** Chỉ số $\text{mAP}@0.5$ tổng hợp trên tất cả các lớp của mô hình dừng lại ở mức trung bình thấp với $\text{mAP}@0.5 = 0.263$. Trong đó, hiệu năng phân lớp có sự phân hóa rõ rệt: lớp *car* đạt điểm số cao nhất (0.525), tiếp nối là *bike* (0.372), *bus* (0.227), *truck* (0.111), và thấp nhất là thực thể *pedestrian* với chỉ vốn vẹn 0.082.

6.4 Kết luận

Điểm mạnh: Mô hình **Faster R-CNN** sở hữu ưu thế nền tảng nhờ vào cơ chế kiến trúc hai giai đoạn (Two-stage object detector) tách biệt. Việc sử dụng mạng đề xuất vùng chuyên biệt RPN kết hợp với cơ chế RoI Pooling giúp mô hình duy trì tính bất biến đối với các phép dịch chuyển hình học (Translation-Invariant) tương đối chặt chẽ. Điều này cho phép mạng lọc và định vị khá chuẩn xác các cấu trúc biên bao của các phương tiện giao thông phổ thông, kích thước lớn hoặc có dải đặc trưng rõ ràng như xe con (*car*) và xe máy (*bike*) ngay cả khi chúng nằm trong vùng biến dạng quang học rìa thấu kính.

Điểm yếu: Điểm yếu chí mạng của mô hình nằm ở tốc độ suy diễn và hiệu năng phân bổ tài nguyên. Do kiến trúc mạng cồng kềnh, phân luồng đa tầng xử lý phức tạp, mô hình tạo ra chi phí tính toán (Computational overhead) rất lớn, khiến tốc độ xử lý fps bị tụt giảm mạnh so với các thuật toán một giai đoạn (One-stage) hiện đại. Đồng thời, qua số liệu thực nghiệm cho thấy mô hình bộc lộ sự thiếu hụt nghiêm trọng trong năng lực trích xuất các đặc trưng ngữ cảnh quy mô nhỏ, dẫn đến tỷ lệ bỏ sót vật thể (*False Negative*) cực kỳ cao đối với người đi bộ (*pedestrian*) và các xe vận tải lớn (*truck*).

Kết luận: Nhìn chung, Faster R-CNN chưa phải là giải pháp thực sự tối ưu đối với bài toán nhận diện luồng giao thông đô thị thời gian thực trên tập dữ liệu thấu kính mắt cá phức tạp như Fisheye8K. Mô hình có xu hướng phù hợp hơn trong các kịch bản phân tích dữ liệu tĩnh hậu kỳ, nơi yêu cầu độ khắt khe về độ chính xác hình học của các đường biên bao đóng được ưu tiên hàng đầu, thay vì các hệ thống giám sát tự động đòi hỏi đáp ứng phản hồi tức thì với tài nguyên phần cứng biên giới hạn.

7 So sánh Hiệu năng giữa các mô hình

Dựa vào kết quả đo được trên tập Test thì mô hình RT-DETR đạt được điểm số mAP@0.5 cao hơn so với YOLOv10-S và Faster-RCNN đạt được (**0.472** > **0.458**(YOLOv10-S) > **0.263**(Faster-RCNN)). Từ kết quả này, nhóm quyết định xem xét YOLOv10-S và RT-DETR, kết hợp thêm yếu tố độ tinh gọn thì trong khi YOLO chỉ có khoảng **7.2 triệu** tham số thì RT-DETR lại là **32 triệu** và thời gian suy luận của YOLO là **nhANH hơn** đáng kể so với mô hình RT-DETR khoảng **2-3x** lần.

Chính vì vậy, sau khi đã cân nhắc trade-off thì nhóm quyết định chọn **YOLOv10-S** để phù hợp với tài nguyên giới hạn, chủ yếu là **CPU** và tối thiểu thời gian chờ suy luận (inference latency).